VISÃO COMPUTACIONAL · PROPOSTA DE PROJETO FINAL

Classificação de estresses bióticos em folhas de café arábica: Machine Learning clássico versus YOLO

Integrantes: Kaíque Medeiros Lima e Erick Bonruque
Dataset: BRACOL (subconjunto *symptom*) · **Data:** 11 de novembro de 2026

1. Descrição do problema

O Brasil é o maior produtor mundial de café, e a produtividade das lavouras depende do controle de pragas e doenças que atacam as folhas. Quatro estresses bióticos são comuns no café arábica: o bicho-mineiro (*Leucoptera coffeella*), a ferrugem (*Hemileia vastatrix*), a mancha-de-phoma (*Phoma* spp.) e a cercosporiose (*Cercospora coffeicola*). O diagnóstico é feito por inspeção visual, que exige experiência e é difícil de escalar. Várias lesões são parecidas: manchas marrons necróticas aparecem no bicho-mineiro, na phoma e na cercosporiose.

O projeto trata o diagnóstico como um problema de **classificação de imagens em 5 classes** (saudável e os quatro estresses), a partir de recortes de sintomas fotografados com smartphone. A mesma tarefa e o mesmo dataset são resolvidos por duas abordagens: uma baseada em atributos extraídos manualmente e classificadores clássicos, outra baseada em uma rede neural profunda da família YOLO.

2. Objetivos

Objetivo geral: comparar, de forma objetiva e reprodutível, uma solução de Machine Learning clássico e uma solução de Deep Learning para identificar estresses bióticos em folhas de café.

Objetivos específicos:

1. Construir um pipeline clássico com pré-processamento, extração de atributos de cor, textura (LBP, Haralick) e forma (HOG) e classificadores supervisionados, com meta de F1 ≥ 0,60.
2. Treinar um classificador YOLO com transferência de aprendizado, com meta de F1 ≥ 0,80.
3. Medir qual grupo de atributos contribui mais para o desempenho do pipeline clássico (ablação).
4. Comparar as soluções por precision, recall, F1, matriz de confusão e análise visual de acertos e falhas.

3. Dataset e origem

O BRACOL (*Brazilian Arabica Coffee Leaf images dataset*) foi publicado por Krohling, Esgario e Ventura (UFES) em 2019, sob licença **CC BY 4.0**. As folhas foram coletadas em Santa Maria de Marechal Floreano, região serrana do Espírito Santo, em diferentes épocas do ano. As fotos mostram a face inferior (abaxial) da folha sobre fundo branco e foram tiradas com cinco smartphones diferentes. A rotulagem foi assistida por um especialista.

O dataset tem três partes: 1.747 folhas inteiras com rótulo de estresse predominante e severidade, 500 imagens com máscaras de segmentação (fundo, folha, sintoma) e o subconjunto

symptom, com recortes de lesões isoladas em que cada imagem contém um único estresse. Este projeto usa o subconjunto *symptom*, que já vem com divisão oficial em treino, validação e teste.

Classe	Treino	Validação	Teste	Total
Saudável	182	40	39	261
Bicho-mineiro	374	83	83	540
Ferrugem	434	93	94	621
Phoma	325	70	69	464
Cercospora	224	49	50	323
Total	**1.539**	**335**	**335**	**2.209**

Tabela 1. Distribuição do subconjunto *symptom*. Imagens JPEG com mediana de 227 × 204 px. A maior razão entre classes é de cerca de 2,4:1 (ferrugem contra saudável).

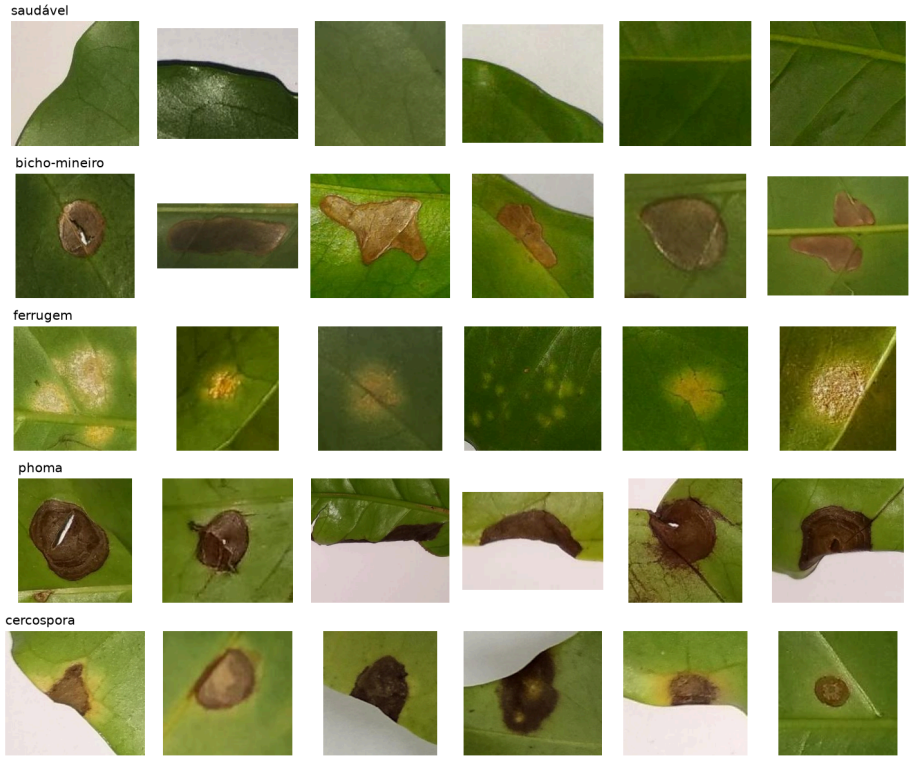


Figura 1. Exemplos do conjunto de treino, uma classe por linha.

O arquivo publicado no Mendeley Data (doi 10.17632/yy2k5y8mxg.1) está truncado: tem só 1.402 imagens de folhas, sem os recortes de sintomas. A versão completa (4.990 arquivos) foi obtida pelo link indicado no repositório oficial dos autores (github.com/esgario/lara2018).

4. Metodologia

- **Protocolo:** o treino ajusta os modelos, a validação escolhe atributos, hiperparâmetros e o checkpoint da rede, e o teste é usado uma única vez, no fim. As duas soluções usam exatamente as mesmas imagens em cada partição.
- **Métrica principal:** F1 macro, que dá o mesmo peso a cada classe e não é inflada pelas classes maiores.

- **Reprodutibilidade:** semente fixa (42), treino determinístico, tudo em um único notebook (`bracol_ml_vs_dl.ipynb`) executado do início ao fim.
- **Ambiente:** Python 3.12, scikit-learn 1.9.1, scikit-image 0.26, OpenCV 5.0, PyTorch 2.11 (CUDA 12.8), Ultralytics 8.4.210, GPU NVIDIA RTX 5060 Ti (16 GB).

5. Solução de Machine Learning clássico

Pré-processamento: cada imagem é redimensionada para 128 × 128 px (interpolação por área) e convertida para HSV, Lab e tons de cinza.

Atributos, organizados em grupos para permitir a ablação:

- **Cor (40):** histogramas normalizados de H (18 bins), S e V (8 bins cada), mais média e desvio padrão dos canais Lab. A ferrugem é amarelo-alaranjada, as lesões necróticas são marrons e a folha sadia é verde.
- **LBP (28):** histogramas de padrões binários locais uniformes, com (P=8, R=1) e (P=16, R=2). Descrevem textura de forma invariante à rotação.
- **Haralick/GLCM (12):** contraste, dissimilaridade, homogeneidade, energia, correlação e ASM, em distâncias 1 e 3, com média de 4 ângulos.
- **HOG (324):** histograma de gradientes orientados em 64 × 64 px, 9 orientações.

Classificadores: SVM com kernel RBF, Random Forest, KNN e Regressão Logística, todos com padronização (`StandardScaler`) e, quando disponível, `class_weight='balanced'`. Cada combinação de hiperparâmetros é treinada no treino e avaliada na validação.

Atributos (SVM RBF, C=10)	Dimensão	F1 macro (val.)
Cor + LBP + GLCM	**80**	**0,845**
Cor + LBP + GLCM + HOG	404	0,811
Só cor	40	0,774
Só LBP	28	0,686
Só HOG	324	0,625
Só GLCM	12	0,571

Tabela 2. Ablação de atributos. A cor sozinha explica a maior parte do desempenho. O HOG piora o resultado quando é adicionado, provavelmente porque descreve a orientação da lesão, que não tem relação com a classe.

Classificador	Melhores hiperparâmetros	F1 macro (val.)
SVM (RBF)	**C = 100, γ = 0,001**	**0,867**
Regressão Logística	C = 1	0,858
Random Forest	400 árvores, max_features = 0,3	0,852
KNN	k = 3, pesos por distância	0,727

Tabela 3. Seleção de classificador com os atributos cor + LBP + GLCM. O SVM foi escolhido para o teste.

6. Solução de Deep Learning (YOLO)

A rede é o **YOLO26-s em modo classificação** (`yolo26s-cls`, Ultralytics), inicializada com pesos pré-treinados no ImageNet (transferência de aprendizado). O modo classificação foi escolhido

porque o BRACOL não tem caixas delimitadoras por tipo de estresse: as máscaras de segmentação só distinguem fundo, folha e sintoma. Também é a forma de resolver o mesmo problema da solução clássica, como exige o enunciado.

- **Entrada:** 224 × 224 px, lote de 64 imagens.
- **Otimização:** AdamW, taxa inicial 5×10^{-4} com decaimento cosseno, 3 épocas de aquecimento, 60 épocas, early stopping com paciência 30. O checkpoint final é o de maior acurácia na validação (época 45, 98,2%).
- **Aumento de dados** (padrão do Ultralytics): RandAugment, espelhamento horizontal, variação de HSV, translação, escala e apagamento aleatório.

Uma primeira execução com o otimizador automático do Ultralytics oscilou: a melhor validação apareceu na época 2 e o treino parou na época 17, com F1 de 0,943 no teste. A troca para AdamW com taxa menor e decaimento cosseno deu uma curva estável. A decisão foi tomada só com base na validação.

O YOLO27 foi anunciado pela Ultralytics em setembro de 2026, mas seus pesos ainda não estavam publicados na versão 8.4.210 usada aqui. Se ele for lançado antes da entrega, a troca exige mudar só o nome do modelo no notebook, e a comparação YOLO26 × YOLO27 pode entrar como experimento adicional.

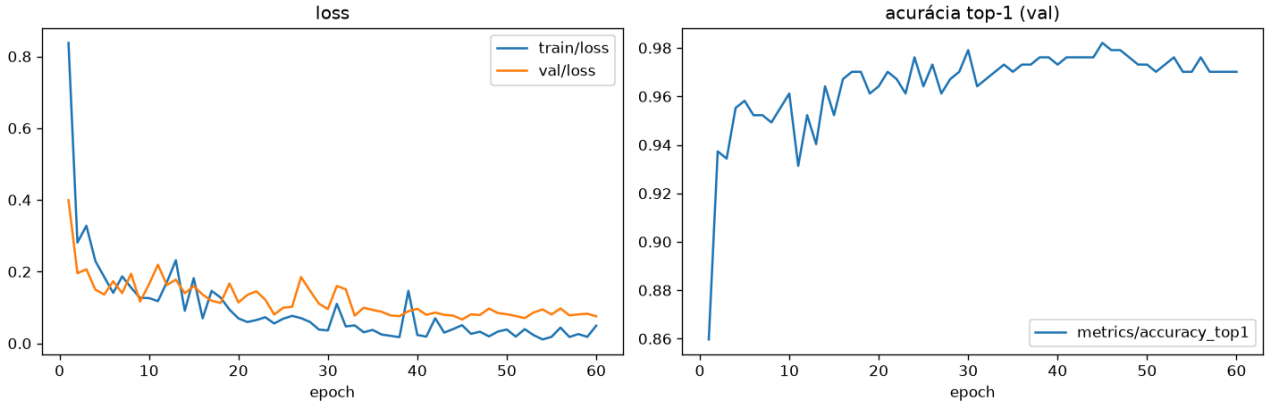


Figura 2. Loss de treino e validação e acurácia top-1 na validação ao longo das épocas.

7. Avaliação experimental e métricas

As duas soluções são avaliadas no conjunto de teste (335 imagens) por precision, recall e F1 por classe e em média macro, acurácia, matriz de confusão e análise visual de casos em que só uma das soluções erra, em que as duas erram e em que as duas acertam. O tempo de inferência por imagem é registrado como informação complementar.

8. Resultados preliminares

0,832	**0,954**	**55 → 15**
F1 macro, ML clássico (meta 0,60)	F1 macro, YOLO26-s-cls (meta 0,80)	erros no teste, de ML para DL

Solução	Precision	Recall	F1 macro	Acurácia	Meta F1
ML: SVM RBF, cor + LBP + GLCM	0,827	0,844	0,832	0,836	0,60 ✓
DL: YOLO26-s-cls	**0,954**	**0,955**	**0,954**	**0,955**	**0,80 ✓**

Tabela 4. Desempenho no conjunto de teste (médias macro).

Classe	F1 ML	F1 DL	Ganho
Saudável	0,905	0,987	+0,08
Bicho-mineiro	0,828	0,934	+0,11
Ferrugem	0,877	0,984	+0,11
Phoma	0,871	0,957	+0,09
Cercospora	0,679	0,909	+0,23

Tabela 5. F1 por classe no teste. A cercosporiose é a classe mais difícil para as duas soluções e a que mais ganha com o DL.

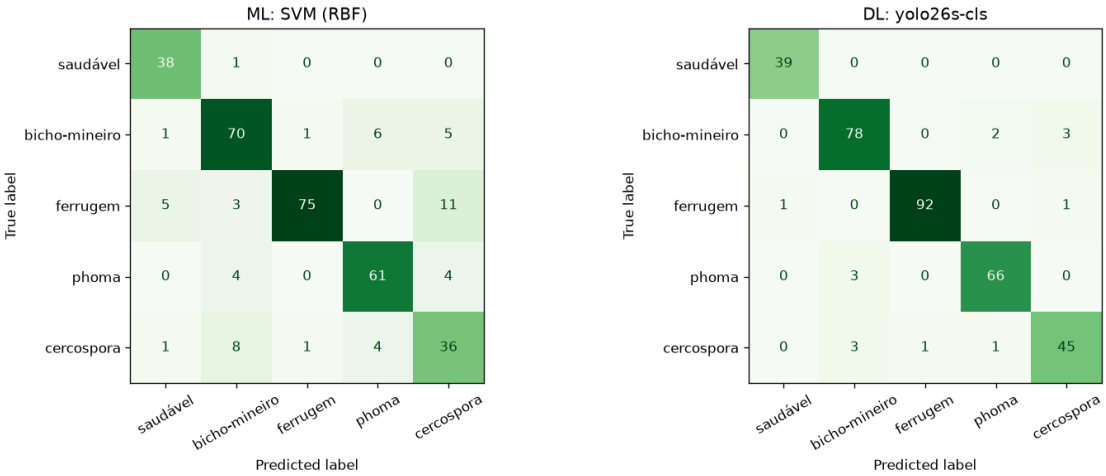


Figura 3. Matrizes de confusão no teste (linhas: classe real; colunas: classe prevista).



Figura 4. Os 12 casos em que as duas soluções erram. Quase todos são lesões marrons necróticas, trocadas entre bicho-mineiro, phoma e cercospora.

9. Análise crítica preliminar

- **As duas metas foram atingidas**, e o DL reduz os erros de 55 para 15 em 335 imagens. Há 43 casos em que só o ML erra e 3 em que só o DL erra.
- **O ML depende da cor.** Ele separa bem as classes de cor distinta (saudável e ferrugem), mas confunde as lesões marrons. Também classifica 11 imagens de ferrugem como cercospora: as duas podem ter halo amarelo, e histogramas globais de cor não capturam a forma da lesão.
- **O DL aprende forma e textura juntas.** O maior ganho é na cercosporiose (+0,23 de F1). Os erros que restam concentram-se nos mesmos pares de classes necróticas, o que sugere limite visual real e possíveis rótulos ambíguos (Figura 4).
- **Custo:** o pipeline clássico treina em segundos na CPU e é interpretável pela ablação. O YOLO exige GPU para treinar em tempo razoável (cerca de 1 s por época aqui).

Limitações e próximos passos

- Cada solução foi treinada uma única vez, com uma semente. Com 50 imagens de cercospora no teste, diferenças de 1 a 2 pontos de F1 estão dentro do ruído. Próximo passo: repetir com várias sementes e reportar média e desvio padrão.
- Os recortes isolam uma única lesão. Em campo, a folha inteira pode ter mais de um estresse. Próximo passo: avaliar no subconjunto de folhas inteiras (1.747 imagens, rótulo de estresse predominante).
- Tempos de inferência medidos de forma simples (ML ≈ 18 ms/imagem na CPU; YOLO 1 a 4 ms/imagem na GPU em lotes de 32), sem benchmark controlado.
- Avaliar o YOLO27 quando os pesos forem publicados.

Referências

1. KROHLING, R. A.; ESGARIO, J. G. M.; VENTURA, J. A. BRACOL: A Brazilian Arabica Coffee Leaf images dataset to identification and quantification of coffee diseases and pests. Mendeley Data, v1, 2019. doi:10.17632/yy2k5y8mxg.1.
2. ESGARIO, J. G. M.; KROHLING, R. A.; VENTURA, J. A. Deep learning for classification and severity estimation of coffee leaf biotic stress. *Computers and Electronics in Agriculture*, v. 169, 105162, 2020.
3. HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, v. 3, n. 6, p. 610–621, 1973.
4. OJALA, T.; PIETIKÄINEN, M.; MÄENPÄÄ, T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE TPAMI*, v. 24, n. 7, p. 971–987, 2002.
5. DALAL, N.; TRIGGS, B. Histograms of oriented gradients for human detection. In: *CVPR*, 2005.
6. CORTES, C.; VAPNIK, V. Support-vector networks. *Machine Learning*, v. 20, p. 273–297, 1995.
7. PEDREGOSA, F. et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
8. JOCHER, G. et al. Ultralytics YOLO. Software, versão 8.4.210, 2026. Disponível em: github.com/ultralytics/ultralytics.